

Zadanie regresji liniowej


Metody systemowe i decyzyjne

Piotr Dąbrowski

na bazie prezentacji dra. Szymona Zaręby

Problem regresji

- **Zmienne wejściowe** (ang. *input variables*): $\mathbf{x} \in \mathcal{X}$
- **Zmienna wyjściowa** (ang. *target variable*): $y \in \mathbb{R}$
- **Problem:** dla zadanego $\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$ przewidzieć wartość y dla nowego \mathbf{x} .



Przykładowy problem

Mieszkanie o liczbie pokoi równej x kosztuje y tys. złotych.
Zebrano następujące dane dotyczące trzech sprzedaży:

x	1	2	3
y	200	400	750

Tabela: Dane dla trzech sprzedaży.

Chcemy przewidywać cenę mieszkania y , jeżeli dane mieszkanie posiada x pokoiów.

Ekstrakcja cech

Macierz $\Phi = [\phi(\mathbf{x}_1) \phi(\mathbf{x}_2) \dots \phi(\mathbf{x}_N)]^T$ (ang. *design matrix*) przyjmuje postać w zależności od definicji cech, np.:

- $\phi(x) = (1 \ x \ x^2)^T$
- $\phi(x) = (1 \ e^{-(x-2)^2} \ e^{-(x-3)^2})^T$

Ekstrakcja cech

x	1	2	3
y	200	400	750

Tabela: Dane dla trzech klientów.

$$\begin{aligned}\phi(x) &= (1 \ x \ x^2)^T \\ &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}\end{aligned}$$

$$\begin{aligned}\phi(x) &= (1 \ e^{-(x-2)^2} \ e^{-(x-3)^2})^T \\ &= \begin{bmatrix} 1 & e^{-1} & e^{-4} \\ 1 & e^0 & e^{-1} \\ 1 & e^{-1} & e^0 \end{bmatrix}\end{aligned}$$

Model

Model regresji liniowej przyjmuje następującą postać:

$$\bar{y}(\mathbf{x}) = \phi(\mathbf{x})^T \mathbf{w},$$

gdzie $\mathbf{w} \in \mathbb{R}^D$ jest wektorem parametrów. Przy macierzowej reprezentacji obserwacji

$$\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \dots \ \mathbf{x}_N]$$

model przyjmuje wygodną postać

$$\bar{\mathbf{y}} = \Phi \mathbf{w}$$

Predykcja

Dla cech $\phi(x) = (1 \ x \ x^2)^T$ oraz wektora parametrów $\mathbf{w} = (1 \ 2 \ 1)^T$, wyznaczyć odpowiedź modelu dla przykładowego wejścia $x = 4$:

$$\phi(4) = (1 \ 4 \ 16)^T$$

$$\mathbf{w} = (1 \ 2 \ 1)^T$$

$$\bar{y} = 1 * 1 + 2 * 4 + 1 * 16 = 25$$

Dla błędu kwadratowego:

$$E(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \bar{\mathbf{y}}\|_2^2$$

- wyznacz gradient $\nabla_{\mathbf{w}} E(\mathbf{w})$
- przyrównaj gradient do zera
- wylicz szukaną wartość

$$E(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \bar{\mathbf{y}}\|_2^2$$

$$\bar{\mathbf{y}} = \mathbf{\Phi} \mathbf{w}$$

$$\begin{aligned} \nabla_{\mathbf{w}} E(\mathbf{w}) &= \nabla_{\mathbf{w}} \left(\frac{1}{2} \|\mathbf{y} - \mathbf{\Phi} \mathbf{w}\|_2^2 \right) \\ &= -2 \frac{1}{2} \mathbf{\Phi}^T (\mathbf{y} - \mathbf{\Phi} \mathbf{w}) \\ &= -\mathbf{\Phi}^T (\mathbf{y} - \mathbf{\Phi} \mathbf{w}) \end{aligned}$$

Wyznacz wartości parametrów minimalizujące błąd $E(\mathbf{w})$:

$$\nabla_{\mathbf{w}} E(\mathbf{w}) = -\Phi^T(\mathbf{y} - \Phi\mathbf{w})$$

$$\Phi^T(\mathbf{y} - \Phi\mathbf{w}) = 0$$

$$\Phi^T\mathbf{y} - \Phi^T\Phi\mathbf{w} = 0$$




$$\Phi^T\mathbf{y} = \Phi^T\Phi\mathbf{w}$$

$$(\Phi^T\Phi)^{-1}\Phi^T\mathbf{y} = \mathbb{I}\mathbf{w}$$

$$\mathbf{w} = (\Phi^T\Phi)^{-1}\Phi^T\mathbf{y}$$

Selekcja modelu

- Wybranie zbyt prostego modelu powoduje, że model nie jest w stanie objąć zależności w danych, **underfitting**
- Wybranie modelu zbyt skomplikowanego powoduje, że model uczy się nie tylko natury danych, ale również wszelkich szumów, **overfitting**



Dla błędu kwadratowego z regularyzacją ℓ_2 (Tichonowa):

$$E_\lambda(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \bar{\mathbf{y}}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

gdzie $\lambda > 0$ jest współczynnikiem regularyzacji.

- wyznacz gradient $\nabla_{\mathbf{w}} E_\lambda(\mathbf{w})$
- przyrównaj gradient do zera
- wylicz szukaną wartość

$$E_{\lambda}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \bar{\mathbf{y}}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$
$$\bar{\mathbf{y}} = \Phi \mathbf{w}$$

$$\begin{aligned}\nabla_{\mathbf{w}} E(\mathbf{w}) &= \nabla_{\mathbf{w}} \left(\frac{1}{2} \|\mathbf{y} - \Phi \mathbf{w}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2 \right) \\ &= -2 \frac{1}{2} \Phi^T (\mathbf{y} - \Phi \mathbf{w}) + \frac{\lambda}{2} 2 \mathbf{w} \\ &= -\Phi^T (\mathbf{y} - \Phi \mathbf{w}) + \lambda \mathbf{w}\end{aligned}$$

Wyznacz wartości parametrów minimalizujące błąd $E_\lambda(\mathbf{w})$:

$$\nabla_{\mathbf{w}} E(\mathbf{w}) = -\Phi^T(\mathbf{y} - \Phi\mathbf{w}) + \lambda\mathbf{w}$$

$$-\Phi^T(\mathbf{y} - \Phi\mathbf{w}) + \lambda\mathbf{w} = 0$$

$$\Phi^T\mathbf{y} - \Phi^T\Phi\mathbf{w} - \lambda\mathbf{w} = 0$$




$$\Phi^T\mathbf{y} = \Phi^T\Phi\mathbf{w} + \lambda\mathbf{w}$$

$$\Phi^T\mathbf{y} = (\Phi^T\Phi + \lambda\mathbb{I})\mathbf{w}$$

$$\mathbf{w} = (\Phi^T\Phi + \lambda\mathbb{I})^{-1}\Phi^T\mathbf{y}$$

Regularyzacja ℓ_2 na parametry

- Poszerzenie kryterium uczenia o wyraz mówiący o tym, że wartości parametrów powinny być małe, **bliskie zeru**
- Wprowadzenie parametru regulującego siłę "ściągnięcia" parametrów w kierunku zera



Podział zbioru danych

- 60% - Zbiór **uczący**, na nim dokonujemy znalezienia wartości parametrów w , które optymalizują kryterium jakości
- 20% - Zbiór **walidacyjny**, na nim dokonujemy znalezienia wartości hiperparametrów M oraz λ , hiperparametry wykorzystywane są do stworzenia modelu uczonego na zbiorze uczącym, na zbiorze walidacyjnym testujemy słuszność hiperparametrów
- 20% - Zbiór **testowy**, na nim podajemy ostateczną skuteczność modelu nauczonego na zbiorze uczącym o hiperparametrach sprawdzonych na zbiorze walidacyjnym